

TP1 - Processamento de arquivos, geração de vocabulário e bag of words

Due today at 11:59 PM•

Closes today at 11:59 PM

Instructions

1) Fazer um programa em Python que receba como entrada um arquivo contendo um texto qualquer e devolva como saída um arquivo de texto contendo o vocabulário (termos de indexação) de tal arquivo.

Exemplo:

Entrada:

"Minha terra tem palmeiras,
Onde canta o Sabiá;
As aves, que aqui gorjeiam,
Não gorjeiam como lá.
Nosso céu tem mais estrelas,
Nossas várzeas têm mais flores,
Nossos bosques têm mais vida,
Nossa vida mais amores."

Saída:

amores
aqui
as
aves
bosques
canta
ceu
como
estrelas
flores
gorjeiam
la
mais
minha
nao
nossa
nossas

nosso
nossos
o
onde
palmeiras
que
sabia
tem
terra
varzeas
vida

Pontos importantes:

- Os termos de indexação do arquivo de saída devem estar em ordem alfabética (existe uma função no Python que faz isso!)
- Ao processar o arquivo de entrada: a) considere todas as palavras como com letras minúsculas e b) desconsidere pontuação e acentuação. Existem funções no Python que fazem isso!
- Faça testes com diferentes arquivos de entrada;

2) Fazer um programa (ou ajustes no seu programa anterior) que recebe como entrada o arquivo de vocabulário e um arquivo de texto representando um documento. O programa deve devolver como saída a representação "bag of words" (presença/ausência de termos) de tal arquivo texto. Exemplo:

Entrada 1:

amores
aqui
as
aves
bosques
canta
ceu
como
estrelas
flores
gorjeiam
la
mais
minha
nao
nossa
nossas
nosso
nossos

o
onde
palmeiras
que
sabia
tem
terra
varzeas
vida

Entrada 2:

"Minha terra tem palmeiras,
Onde canta o Sabiá;
As aves, que aqui gorjeiam,
Não gorjeiam como lá."

Saída:

```
[0, 1, 1, 1, 0, 1, 0, 1, 0, 0, 1, 1, 0, 1, 1, 0, 0, 0, 0, 1, 1, 1,  
1, 1, 1, 1, 0, 0]
```

Outros pontos importantes:

- Pense em como você poderia generalizar o seu programa lendo diversos arquivos (documentos) de uma vez.
- Dentro do possível, tente modularizar o seu código (funções, etc.).

Entrega/Desenvolvimento:

- Na sala de aula, use IDEs online como o Google Colab (colab.google.com). Em casa, podem usar o Pycharm ou o seguir com o próprio Colab (há inclusive extensão do Colab para o vscode). Cada grupo deve anexar como resposta o arquivo Jupyter Notebook (extensão .ipynb) correspondente aos itens 1) e 2) - separe-os em diferentes células do notebook - bem como os arquivos de entrada correspondentes.
- Colocar na célula inicial do Notebook o nome completo dos integrantes do Grupo (**exigido: 3 a 5 membros por grupo**)

Algumas dicas:

- Primeiro o arquivo deve ser aberto usando a função "open()". Depois o arquivo deve ser lido usando a função "read()".
- A função unidecode da biblioteca "Unidecode" ajuda no tratamento das palavras chave.
- A função split() é muito importante!

- Aprender como percorrer um vetor em Python será essencial para separar as palavras repetidas e criar o vocabulário.